LAPORAN UJIAN TENGAH SEMESTER

Implementasi Big Data Pipeline Menggunakan PySpark, Parquet, Machine Learning, dan Streamlit Dashboard

Untuk memenuhi tugas mata kuliah Teknologi Big Data

Dosen Pengampu: Bapak Muhayat, S.Ag., M.IT.

Oleh:

Siti Magfiratun Warahmah

Nim: 230104040059

PROGRAM STUDI TEKNOLOGI INFORMASI

FAKULTAS DAKWAH DAN ILMU KOMUNIKASI

UNIVERSITAS ISLAM NEGERI ANTASARI BANJARMASIN

TAHUN 2026

Smart Campus Attendance Analytics (NIM akhir ganjil: 230104040059)

Studi Kasus:

Universitas ingin menganalisis kepadatan mahasiswa pada beberapa gedung menggunakan data tapping kartu mahasiswa untuk memprediksi jam sibuk kampus.

1. Tujuan Praktikum

Tujuan dari praktikum ini adalah:

a) Mengimplementasikan Apache Spark (PySpark) untuk proses pengolahan data Big Data.
b) Membuat data simulasi kehadiran mahasiswa menggunakan Python.
c) Melakukan transformasi data untuk mendapatkan total mahasiswa per gedung dan tren kehadiran mahasiswa.
d) Menyimpan hasil pengolahan data ke dalam format Parquet.
e) Membangun dashboard interaktif menggunakan Streamlit dan Plotly.
f) Mengimplementasikan Machine Learning menggunakan Linear Regression untuk memprediksi kepadatan mahasiswa berdasarkan jam tertentu.
g) Menganalisis jam tersibuk kampus berdasarkan hasil visualisasi dashboard.

2. Konsep Dasar

2.1 Big Data

Big Data merupakan kumpulan data berukuran besar yang memerlukan teknologi khusus untuk proses pengolahan dan analisis data secara cepat dan efisien. Pada praktikum ini, konsep Big Data digunakan untuk menganalisis kepadatan mahasiswa kampus berdasarkan data kehadiran mahasiswa pada beberapa gedung kampus.

2.2 Apache Spark (PySpark)

Apache Spark merupakan framework Big Data yang digunakan untuk memproses data dalam jumlah besar secara cepat dan efisien. PySpark adalah API Apache Spark berbasis Python yang digunakan untuk pengolahan dan analisis data. Pada praktikum ini, PySpark digunakan untuk:

- membuat Spark Session,
- membuat Spark DataFrame,
- melakukan transformasi data,
- melakukan agregasi data,
- serta menyimpan data dalam format Parquet.

2.3 Parquet

Parquet merupakan format penyimpanan data berbasis kolom (*columnar storage*) yang umum digunakan dalam Big Data karena memiliki ukuran file lebih kecil dan proses pembacaan data lebih cepat dibandingkan format biasa seperti CSV. Pada praktikum ini, data hasil transformasi disimpan ke dalam format Parquet pada folder:

- output/attendance_total
- output/attendance_time
- output/ml_attendance

2.4 Streamlit dan Plotly

Streamlit merupakan framework Python yang digunakan untuk membuat dashboard interaktif berbasis web, sedangkan Plotly digunakan untuk membuat visualisasi grafik interaktif. Pada praktikum ini, Streamlit dan Plotly digunakan untuk menampilkan dashboard *Smart Campus Attendance Analytics* yang berisi:

- filter gedung,
- KPI total mahasiswa,
- grafik tren kehadiran,
- serta prediksi kepadatan mahasiswa.

2.5 Machine Learning

Machine Learning merupakan teknologi yang memungkinkan sistem melakukan prediksi berdasarkan data yang tersedia. Pada praktikum ini digunakan metode Linear Regression dari library Scikit-Learn untuk memprediksi jumlah mahasiswa berdasarkan jam tertentu. Model machine learning diintegrasikan ke dalam dashboard sehingga pengguna dapat melihat prediksi jumlah mahasiswa menggunakan slider interaktif.

2.6 Smart Campus Attendance Analytics

Smart Campus Attendance Analytics merupakan sistem analisis kehadiran mahasiswa berbasis Big Data yang digunakan untuk memantau kepadatan mahasiswa pada area kampus. Sistem ini dibangun menggunakan pipeline Big Data yang terdiri dari:

Attendance Data → Spark Analytics → Parquet Storage → AI Prediction → Streamlit Dashboard

Melalui sistem ini, data kehadiran mahasiswa dapat dianalisis untuk mengetahui tren kepadatan kampus serta memprediksi jam tersibuk berdasarkan hasil visualisasi dashboard dan machine learning.

3. Dokumentasi Implementasi Praktikum

Hasil implementasi praktikum ditunjukkan melalui beberapa dokumentasi berikut.

Screenshot Script Python Engine (main_uts_230104040059.py)

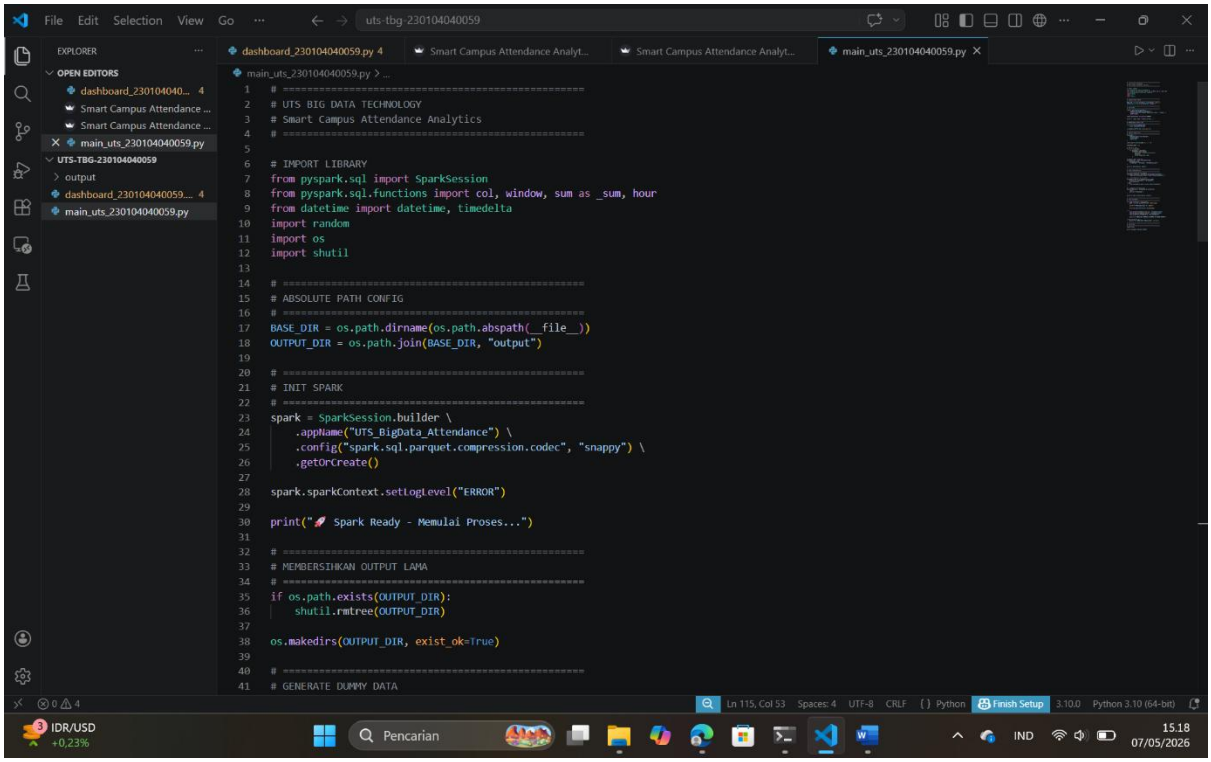

```python
# ==============================================
# UTS BIG DATA TECHNOLOGY
# Smart Campus Attendance Analytics
# ==============================================

# IMPORT LIBRARY
from pyspark.sql import SparkSession
from pyspark.sql.functions import col, window, sum as _sum, hour
from datetime import datetime, timedelta
import random
import os
import shutil

# ==============================================
# ABSOLUTE PATH CONFIG
# ==============================================
BASE_DIR = os.path.dirname(os.path.abspath(__file__))
OUTPUT_DIR = os.path.join(BASE_DIR, "output")

# ==============================================
# INIT SPARK
# ==============================================
spark = SparkSession.builder \
    .appName("UTS_BigData_Attendance") \
    .config("spark.sql.parquet.compression.codec", "snappy") \
    .getOrCreate()

spark.sparkContext.setLogLevel("ERROR")

print("🚀 Spark Ready - Memulai Proses...")

# ==============================================
# MEMBERSIHKAN OUTPUT LAMA
# ==============================================
if os.path.exists(OUTPUT_DIR):
    shutil.rmtree(OUTPUT_DIR)

os.makedirs(OUTPUT_DIR, exist_ok=True)

# ==============================================
# GENERATE DUMMY DATA
```

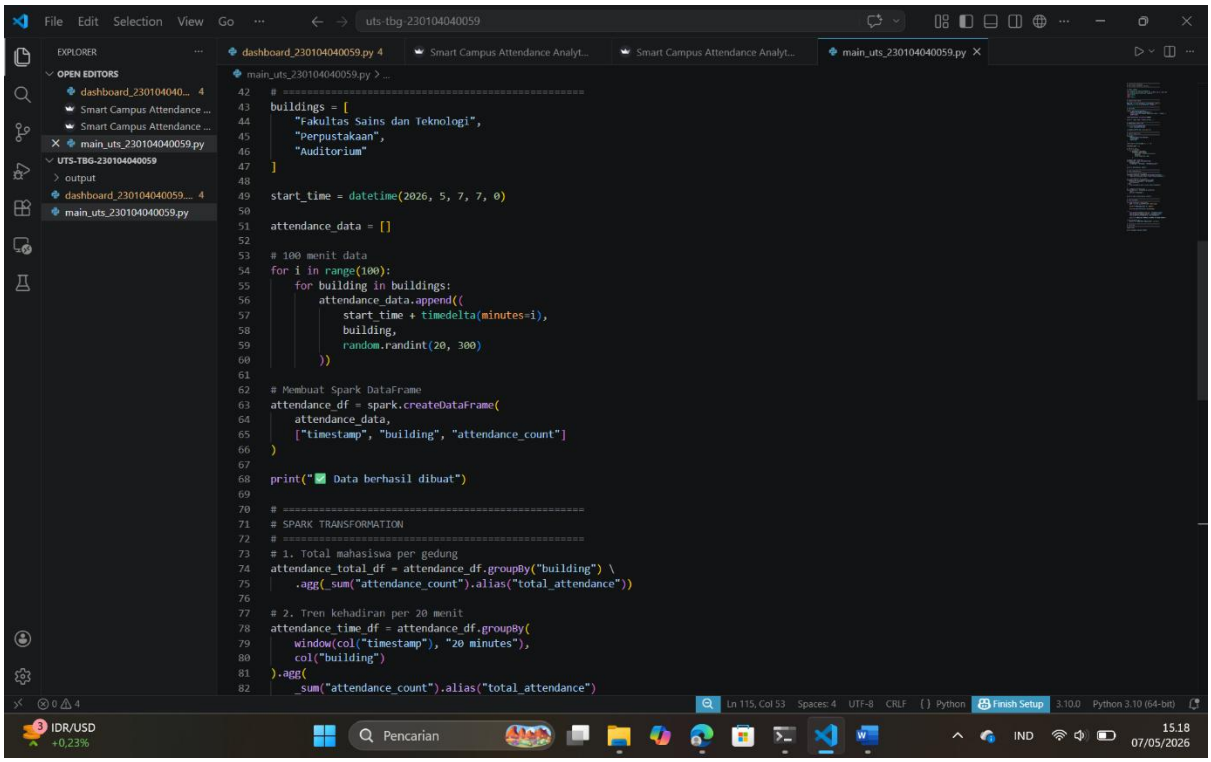

```python
# ==============================================
buildings = [
    "Fakultas Sains dan Teknologi",
    "Perpustakaan",
    "Auditorium"
]

start_time = datetime(2026, 5, 7, 7, 0)

attendance_data = []

# 100 menit data
for i in range(100):
    for building in buildings:
        attendance_data.append((
            start_time + timedelta(minutes=i),
            building,
            random.randint(20, 300)
        ))

# Membuat Spark DataFrame
attendance_df = spark.createDataFrame(
    attendance_data,
    ["timestamp", "building", "attendance_count"]
)

print("✅ Data berhasil dibuat")

# ==============================================
# SPARK TRANSFORMATION
# ==============================================
# 1. Total mahasiswa per gedung
attendance_total_df = attendance_df.groupBy("building") \
    .agg(_sum("attendance_count").alias("total_attendance"))

# 2. Tren kehadiran per 20 menit
attendance_time_df = attendance_df.groupBy(
    window(col("timestamp"), "20 minutes"),
    col("building")
).agg(
    _sum("attendance_count").alias("total_attendance")
```

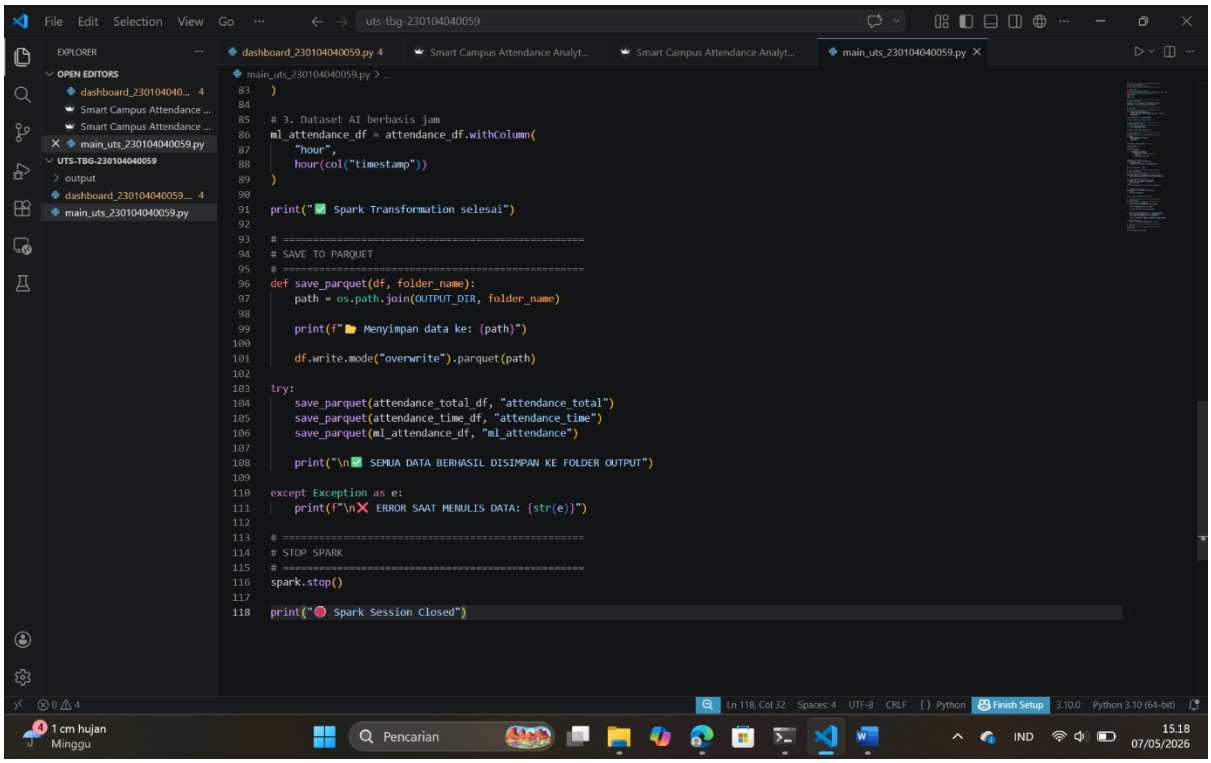

```python
)

# 3. Dataset AI berbasis jam
ml_attendance_df = attendance_df.withColumn(
    "hour",
    hour(col("timestamp"))
)

print("✅ Spark Transformation selesai")

# ==============================================
# SAVE TO PARQUET
# ==============================================
def save_parquet(df, folder_name):
    path = os.path.join(OUTPUT_DIR, folder_name)

    print(f"📂 Menyimpan data ke: {path}")

    df.write.mode("overwrite").parquet(path)

try:
    save_parquet(attendance_total_df, "attendance_total")
    save_parquet(attendance_time_df, "attendance_time")
    save_parquet(ml_attendance_df, "ml_attendance")

    print("\n✅ SEMUA DATA BERHASIL DISIMPAN KE FOLDER OUTPUT")

except Exception as e:
    print(f"\n❌ ERROR SAAT MENULIS DATA: {str(e)}")

# ==============================================
# STOP SPARK
# ==============================================
spark.stop()

print("🔴 Spark Session Closed")
```

Screenshot Script Python Dashboard (dashboard_230104040059.py)

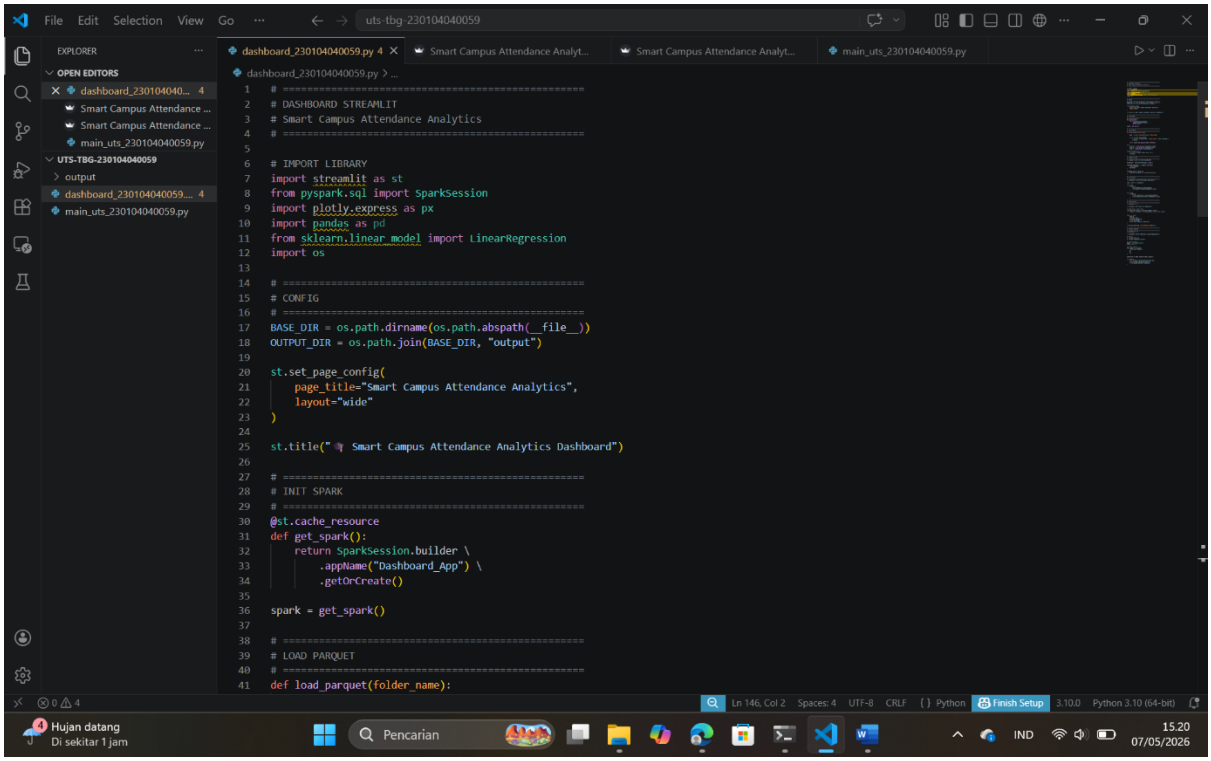

```python
# ==============================================
# DASHBOARD STREAMLIT
# Smart Campus Attendance Analytics
# ==============================================

# IMPORT LIBRARY
import streamlit as st
from pyspark.sql import SparkSession
import plotly.express as px
import pandas as pd
from sklearn.linear_model import LinearRegression
import os

# ==============================================
# CONFIG
# ==============================================
BASE_DIR = os.path.dirname(os.path.abspath(__file__))
OUTPUT_DIR = os.path.join(BASE_DIR, "output")

st.set_page_config(
    page_title="Smart Campus Attendance Analytics",
    layout="wide"
)

st.title("📊 Smart Campus Attendance Analytics Dashboard")

# ==============================================
# INIT SPARK
# ==============================================
@st.cache_resource
def get_spark():
    return SparkSession.builder \
        .appName("Dashboard_App") \
        .getOrCreate()

spark = get_spark()

# ==============================================
# LOAD PARQUET
# ==============================================
def load_parquet(folder_name):
```

```python
def load_parquet(folder_name):

    path = os.path.join(OUTPUT_DIR, folder_name)

    if not os.path.exists(path):
        st.error(f"❌ Folder data '{folder_name}' tidak ditemukan!")
        st.stop()

    return spark.read.parquet(path).toPandas()

try:
    total_df = load_parquet("attendance_total")
    time_df = load_parquet("attendance_time")
    ml_df = load_parquet("ml_attendance")

except Exception as e:
    st.error(f"❌ Gagal memuat data: {e}")
    st.stop()

# ==============================================
# SIDEBAR FILTER
# ==============================================
st.sidebar.title("📌 Filter Dashboard")

buildings = total_df["building"].unique()

selected_building = st.sidebar.selectbox(
    "Pilih Gedung",
    buildings
)

filtered_total = total_df[
    total_df["building"] == selected_building
]

# ==============================================
# KPI METRICS
# ==============================================
st.subheader("📊 Key Performance Indicators")

col1, col2 = st.columns(2)
```

```python

with col1:
    st.metric(
        "Total Mahasiswa (Semua Gedung)",
        int(total_df["total_attendance"].sum())
    )

with col2:
    st.metric(
        f"Total Mahasiswa di {selected_building}",
        int(filtered_total["total_attendance"].sum())
    )

# ==============================================
# VISUALIZATION
# ==============================================
st.markdown("---")

st.subheader("📈 Grafik Tren Kehadiran")

# Memperbaiki format waktu
time_df["start_time"] = time_df["window"].apply(
    lambda x: x["start"] if isinstance(x, dict) else x.start
)

fig = px.line(
    time_df,
    x="start_time",
    y="total_attendance",
    color="building",
    title="Tren Kehadiran Mahasiswa"
)

st.plotly_chart(fig, use_container_width=True)

# ==============================================
# MACHINE LEARNING
# ==============================================
st.markdown("---")

st.subheader("🤖 AI Prediction (Linear Regression)")
```

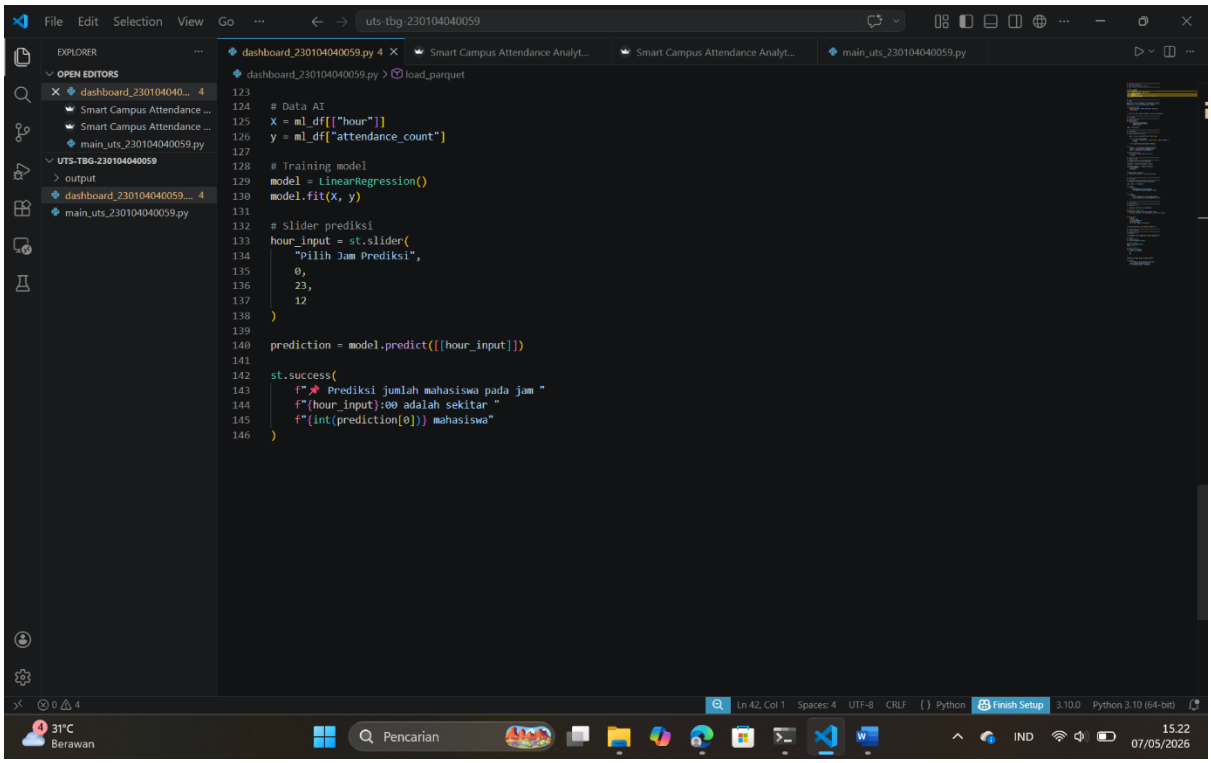

Screenshot Parquet berhasil

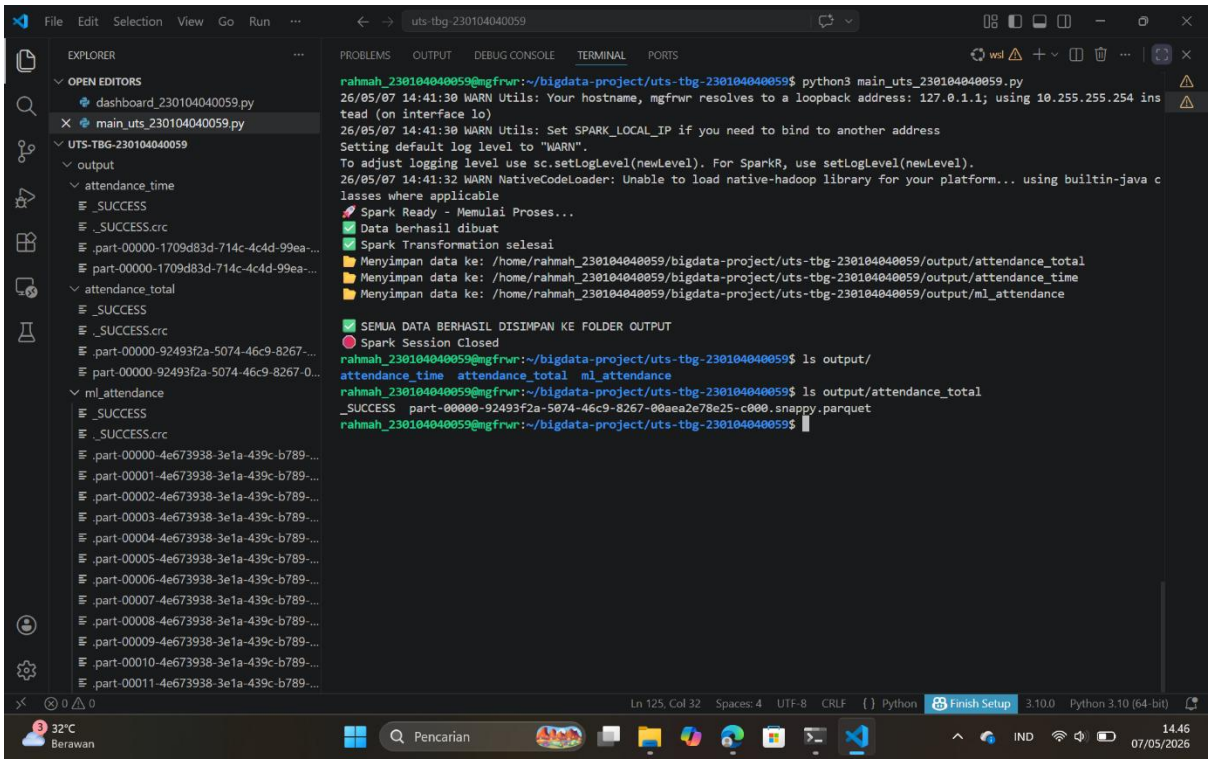

Screenshot Dashboard

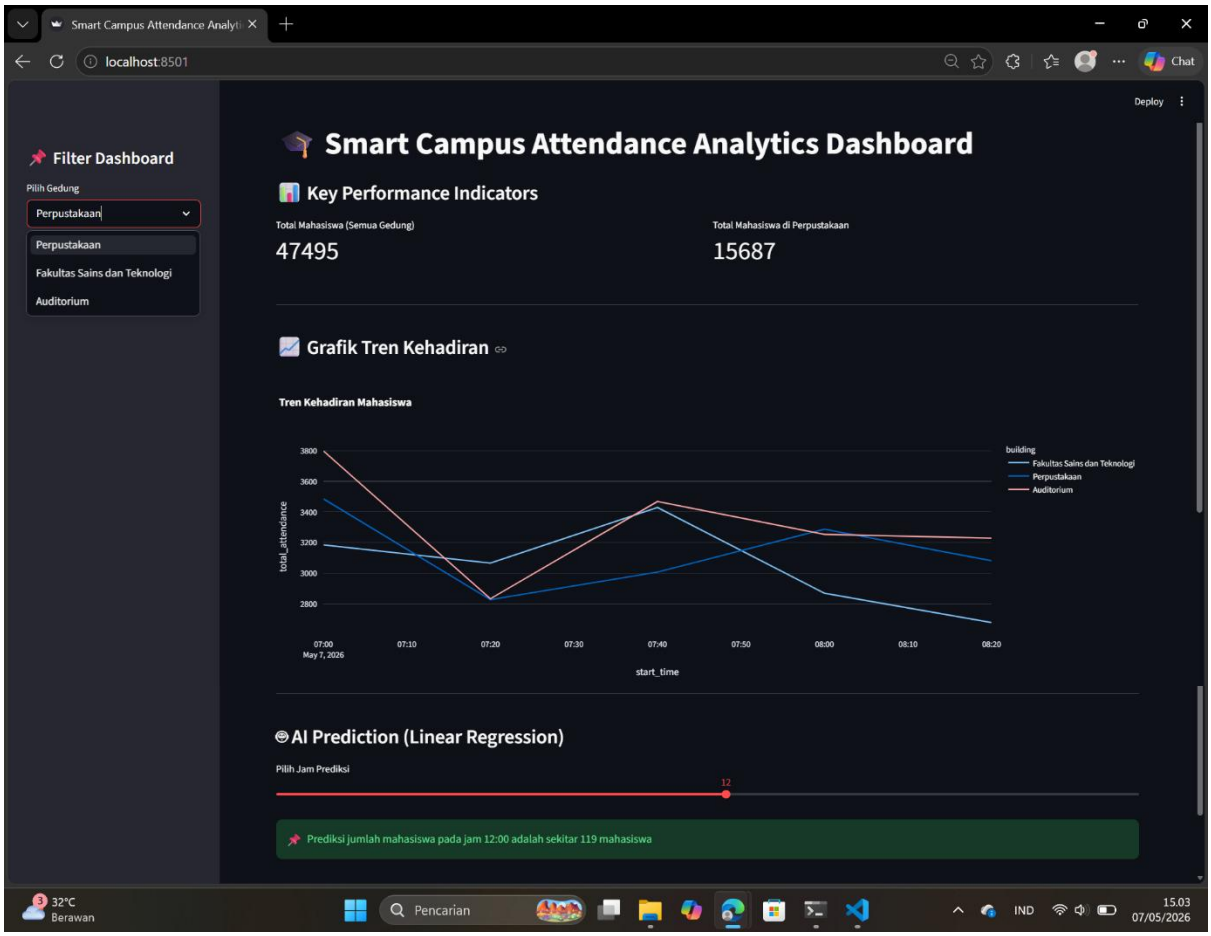

4. Hasil dan Pembahasan

Berdasarkan hasil implementasi yang telah dilakukan, sistem *Smart Campus Attendance Analytics* berhasil dijalankan menggunakan Apache Spark, PySpark, Streamlit, dan Machine Learning. Proses dimulai dari pembuatan data simulasi kehadiran mahasiswa pada beberapa gedung kampus, yaitu Perpustakaan, Fakultas Sains dan Teknologi, serta Auditorium. Data kemudian diproses menggunakan Spark Transformation untuk menghasilkan total kehadiran mahasiswa, tren kehadiran berdasarkan waktu, dan dataset prediksi berbasis jam.

Hasil pengolahan data berhasil disimpan ke dalam format Parquet pada folder output seperti attendance_total, attendance_time, dan ml_attendance. Selain itu, dashboard Streamlit berhasil menampilkan visualisasi data secara interaktif berupa KPI total mahasiswa, grafik tren kehadiran mahasiswa, filter gedung kampus, serta fitur AI Prediction menggunakan metode Linear Regression untuk memprediksi jumlah mahasiswa berdasarkan jam tertentu.

4.1 Analisis Jam Tersibuk Kampus

Berdasarkan hasil visualisasi dashboard *Smart Campus Attendance Analytics*, jam tersibuk kampus terjadi pada rentang waktu sekitar pukul 07.40. Hal tersebut terlihat pada grafik tren kehadiran mahasiswa yang menunjukkan peningkatan jumlah mahasiswa pada hampir seluruh gedung kampus. Pada grafik visualisasi, jumlah kehadiran mahasiswa di gedung Auditorium dan Fakultas Sains dan Teknologi mengalami peningkatan signifikan pada pukul 07.40 dibandingkan waktu lainnya. Sedangkan gedung Perpustakaan menunjukkan tren yang lebih stabil namun tetap mengalami peningkatan jumlah mahasiswa pada jam tersebut.

Selain itu, dashboard juga menampilkan total mahasiswa seluruh gedung sebanyak 47.495 mahasiswa, sedangkan total mahasiswa pada gedung Perpustakaan mencapai 15.687 mahasiswa. Hal ini menunjukkan bahwa gedung Perpustakaan memiliki tingkat aktivitas mahasiswa yang cukup tinggi. Pada fitur AI Prediction menggunakan Linear Regression, sistem berhasil memberikan prediksi jumlah mahasiswa pada pukul 12.00 sekitar 119 mahasiswa. Hasil prediksi tersebut menunjukkan bahwa jumlah mahasiswa pada siang hari mengalami penurunan dibandingkan jam sibuk pagi hari.

Berdasarkan hasil analisis tersebut, dapat disimpulkan bahwa aktivitas mahasiswa paling padat terjadi pada pagi hari, khususnya sekitar pukul 07.40, sehingga waktu tersebut dapat dikategorikan sebagai jam tersibuk kampus.

5. Kesimpulan

Berdasarkan hasil praktikum, implementasi Big Data Pipeline menggunakan PySpark, Parquet, Machine Learning, dan Streamlit Dashboard berhasil dilakukan dengan baik. Sistem mampu melakukan pengolahan, penyimpanan, visualisasi, serta prediksi data kehadiran mahasiswa sehingga dapat membantu proses monitoring tren dan kepadatan mahasiswa di lingkungan kampus secara lebih cepat dan informatif.

6. Repository GitHub

Seluruh source code dan file yang digunakan dalam Ujian Tengah Semester (UTS) Teknologi Big Data ini disimpan dalam repository GitHub yang dapat diakses melalui link berikut:
https://github.com/Siti-Magfiratun-Warahmah/Big-Data-UTS-Siti-Magfiratun-Warahmah-230104040059